Latent space

김영은

Manifold theory

고차원 데이터 $X \subset \mathbb{R}^D$ 는 저차원 다양체 근처에 분포한다고 가정

목적: $d \ll D$인 잠재공간 $Z \subset \mathbb{R}^d$를 찾아서 학습·추론·생성을 단순화

- 데이터 생성 과정: $x = g_\theta(z) + \epsilon, \quad z \sim p(z),\ \epsilon \sim \mathcal{N}(0, \sigma^2 I)$
- 다양체 차원: $\dim(\mathcal{M}) = d \ll D$

변수 정리

- $x \in \mathbb{R}^D$: 관측 벡터(이미지, 음성 등)
- $z \in \mathbb{R}^d$: 잠재벡터(요인/속성)
- $f_\phi : X \to Z$: 인코더(추출)
- $g_\theta : Z \to X$: 디코더(재구성/생성)
- $p_\theta(x|z)$: 생성 분포, $p(z)$: 사전분포, $q_\phi(z|x)$: 근사 사후
- 손실/목표: 재구성 오차, 정규화 항, 변분하한(ELBO), 적대적 목적 등

  - D: 입력 차원, d: 잠재 차원(권장 시작값: 16~256)
  - θ, ϕ: 디코더/인코더 파라미터
  - $\mu(x), \sigma(x)$: VAE의 평균·표준편차 출력
  - $\epsilon \sim \mathcal{N}(0, I)$: 재파라미터화 노이즈

선형 잠재모형: PCA (Latent의 최소 단위)

PCA는 선형 인코더/디코더로 보는 가장 단순한 잠재모형

공분산의 고유분해로 주성분 축 획득 → 차원 축소·재구성

- 평균 제거: $\tilde{x} = x - \bar{x}$
- 공분산: $S = \frac{1}{N}\sum_{i=1}^{N} \tilde{x}_i \tilde{x}_i^\top$
- 고유분해: $S = U \Lambda U^\top$
- 인코딩(투영): $z = U_d^\top \tilde{x}$
- 디코딩(역투영): $\hat{x} = \bar{x} + U_d z$
- 선형 AE와의 등가성(정규화 조건 하): 선형 AE 최적해 ↔ PCA

오토인코더(AE): 비선형 잠재공간의 출발점

인코더 f_ϕ, 디코더 g_θ

Undercomplete($d \ll D$) 또는 Regularized(스파스, 드롭아웃 등)로 정보 압축

- 재구성 손실: $\mathcal{L}\mathrm{AE} = \mathbb{E}x \sim \mathcal{D}\left[\|x - g_\theta(f_\phi(x))\|_2^2\right]$
- 선형 AE(한 층, MSE) ⇒ PCA에 수렴(조건부)

$$x \to f_\phi(x) = z \to g_\theta(z) = \hat{x}$$

변분오토인코더(VAE): 확률적 잠재공간

확률적 인코딩 $q_\phi(z|x)$ 과 생성 $p_\theta(x|z)$

1. $\log p_\theta(x) = \log \int p_\theta(x|z)p(z)\,dz$
2. 임의의 $q_\phi(z|x)$ 에 대해

$$\log p_\theta(x) \geq \mathbb{E}q\phi(z|x)[\log p_\theta(x|z)] - \mathrm{KL}\left(q_\phi(z|x) \,\|\, p(z)\right) := \mathcal{L}_{\mathrm{ELBO}}$$

최대화: 재구성항 ↑, KL정규화로 $q_\phi(z|x)$ 를 $p(z)$ 에 가깝게

- $q_\phi(z|x) = \mathcal{N}\left(z; \mu(x), \mathrm{diag}(\sigma^2(x))\right)$
- 재파라미터화: $z = \mu(x) + \sigma(x) \odot \epsilon,\ \ \epsilon \sim \mathcal{N}(0, I)$
- 사전분포 기본값: $p(z) = \mathcal{N}(0, I)$
- β-VAE: $\mathcal{L} = \mathbb{E}[\log p_\theta(x|z)] - \beta\,\mathrm{KL}(\cdot)$ 로 분해도↑

GAN의 잠재공간: 생성 중심 뷰

$z \sim p(z)$ 를 입력받아 $G_\theta(z)$ 가 샘플 생성

판별자 D_ψ 와의 미니맥스 학습으로 데이터 분포 근사

$$\min_\theta \max_\psi \mathbb{E}x \sim pdata[\log D_\psi(x)] + \mathbb{E}z \sim p(z)[\log(1 - D\psi(G_\theta(z)))]$$

- 선형 보간: $z(\alpha) = (1-\alpha)z_1 + \alpha z_2$
- 속성 벡터: $v_{\text{attr}} = \bar{z}\text{class A} - \bar{z}\text{class B}$, $G(z + v_{\text{attr}})$
- Truncation trick: z 의 분산을 줄여 품질↑, 다양성↓(균형 필요)

확산모형과 Latent Diffusion

픽셀공간 확산은 비용↑ → VAE로 압축한 잠재공간에서 확산(Stable Diffusion류)

시간에 따라 노이즈를 추가/제거하여 $p(x)$ 복원

- 전진과정: $q(x_t|x_{t-1}) = \mathcal{N}(\sqrt{1-\beta_t}\ x_{t-1},\ \beta_t I)$
- 역과정 학습: $\epsilon_\theta(x_t, t)$ 로 노이즈 예측, MSE 손실
- Latent Diffusion: $x \to z$ (사전학습 VAE 인코더) 후 z_t 에 확산 적용 → 디코더로 x 복원

잠재공간에서의 거리와 기하

- 단순 유클리드 거리 $\|z_1 - z_2\|_2$ 는 디코더의 왜곡을 무시
- 리만 기하 관점: 디코더 야코비안 $J(z) = \frac{\partial g_\theta(z)}{\partial z}$

  푸시포워드 메트릭: $G(z) = J(z)^\top J(z)$

  짧은 곡선 길이(근사): $ds^2 = dz^\top G(z) dz$

  "지오데식 보간"은 $G(z)$ 를 고려(실무에선 근사/수치비용 큼)

잠재공간의 대표 연산

- **보간(Interpolation)**: $z(\alpha) = (1-\alpha)z_a + \alpha z_b$
- **벡터 산술(Attribute Editing)**: $z' = z + \lambda v_{\text{attr}}$
- **클러스터링**: k-means on z (코사인/유클리드)
- **최근접 검색**: z 공간 k-NN
- **선형 판별(Linear probe)**: $\hat{y} = Wz + b$ 의 정확도로 선형분리 가능성 평가

Latent space