Data Generation

Kim youngeun
Jeonju university, Korea

Data Generation

데이터 분포 자체를 학습하고

새로운 샘플을 만들어내는 것

Learning Data Distribution

$P(y \mid x)$	일반적인 분류 모델
$P(x)$	데이터 생성 모델
$P(x \mid y)$	조건부 생성

즉, '**이 데이터가 어떻게 생겼는가**' 자체를 모델링

Generative Model

GAN (Generative Adversarial Network)

VAE (Variational Autoencoder)

Diffusion Model

GAN *Generative Adversarial Network*

$$\min_G \max_D \; \mathbb{E}_{x \sim p_{data}}[\log D(x)] + \mathbb{E}_{z \sim p(z)}[\log(1 - D(G(z)))]$$

Generator G: 가짜 데이터 생성

Discriminator D: 진짜/가짜 판별

서로 경쟁하면서 학습

G는 D를 속이려고 함

D는 더 정확히 구분하려 함

이미지 생성 매우 강력

학습 불안정

VAE *Variational Autoencoder*

$$\mathcal{L} = \mathbb{E}_{q(z|x)}[\log p(x|z)] - D_{KL}(q(z|x)\|p(z))$$

Encoder: x→z

Decoder: z→x

데이터를 latent space로 압축
그 공간에서 샘플링 후 복원

안정적 학습
생성 품질은 GAN보다 흐림

Diffusion Model

데이터를 점점 노이즈로 만들고
다시 복원하는 모델

Diffusion Model

$$q(x_t|x_{t-1}) = \mathcal{N}(x_t; \sqrt{1-\beta_t}x_{t-1}, \beta_t I)$$

Forward

노이즈 추가

$$p_\theta(x_{t-1}|x_t)$$

Reverse

복원

모델이 노이즈 제거 방법을 학습

매우 안정적

현재 SOTA

계산량 큼

Latent Space

$$z \sim \mathcal{N}(0, I)$$

모든 생성 모델의 핵심

$$x = G(z)$$

단순한 분포에서 시작해 복잡한 데이터 생성

Overall flow

1. 단순한 분포 (노이즈) 생성

2. 신경망을 통해 변형

3. 실제 데이터처럼 보이게 만듦

Point

$$z \to Wz + b$$ 선형대수

$$\sigma(\cdot)$$ 비선형

$$z \to x$$ 반복

Data Generation

Kim youngeun