Experiments

김영은

큰 파라미터 모델과의 정량 비교

ViT 원 논문은 거대한 사전학습 데이터를 전제로 할 때만 CNN을 압도할 수 있다 함

“데이터 + 모델 스케일”이 핵심이라는 점을 반복적으로 언급

AN IMAGE IS WORTH 16X16 WORDS TRANSFORMERS FOR IMAGE RECOGNITION AT SCALE ,Alexey Dosovitskiy Et al,. 2021

큰 파라미터 모델과의 정량 비교

실제로 ViT-B → ViT-L → ViT-H로 갈수록 성능이 좋아지지만,

데이터가 충분하지 않으면 성능이 오히려 불안정해지거나 수렴이 어려운 문제 有

AN IMAGE IS WORTH 16X16 WORDS TRANSFORMERS FOR IMAGE RECOGNITION AT SCALE ,Alexey Dosovitskiy Et al,. 2021

큰 파라미터 모델과의 정량 비교

MAT는 동적 k-NN 그래프 + 클래스 프로토타입 기반 매니폴드를 사용해 표현공간을 정규화

모델이 커질수록 더 심해지는

과도한 자유도 / over-fitting / noise-sensitive attention

구조적으로 제어할 수 있다는 “가설” 有

AN IMAGE IS WORTH 16X16 WORDS TRANSFORMERS FOR IMAGE RECOGNITION AT SCALE ,Alexey Dosovitskiy Et al,. 2021

큰 파라미터 모델과의 정량 비교

Base-scale에서 확인한 10.72%p 향상,

Early Saturation 완화,

고 Epoch에서도 계속 오르는 성능(500 epoch 90.43%)이

Large/Huge scale에서도 유지·증폭되는지를 검증 필요

AN IMAGE IS WORTH 16X16 WORDS TRANSFORMERS FOR IMAGE RECOGNITION AT SCALE ,Alexey Dosovitskiy Et al,. 2021

큰 파라미터 모델과의 정량 비교

Base-scale에서 확인한 10.72%p 향상,

Early Saturation 완화,

고 Epoch에서도 계속 오르는 성능(500 epoch 90.43%)이

Large/Huge scale에서도 유지·증폭되는지를 검증 필요

BENCHMARKING NEURAL NETWORK ROBUSTNESS TO COMMON CORRUPTIONS AND PERTURBATIONS, Dan Hendrycks Et al., 2019

Swin Transformer: Hierarchical Vision Transformer using Shifted Windows, Ze Liu Et al., 2021

강력한 어그멘테이션·스케줄러 도입 후 SOTA 도전

상대적으로 기본적인 세팅 + MAT 구조 개선만으로도

10.72%p 향상,

수렴 가속,

장기 학습에서의 안정성

강력한 어그멘테이션·스케줄러 도입 후 SOTA 도전

최신 SOTA ViT/ConvNet들은

Mixup / CutMix / RandAugment / AugMix / DeepAugment

Cosine LR, OneCycle, EMA, Label Smoothing

같은 강력한 데이터 어그멘테이션·스케줄링 레시피

강력한 어그멘테이션·스케줄러 도입 후 SOTA 도전

1. 동일한 레시피 조건에서 Standard ViT vs MAT를 비교→ 구조 덕분에 이만큼 이긴다

2. MAT가 튜닝이 아니라 구조적 개선이라는 것을 증명

강력한 어그멘테이션·스케줄러 도입 후 SOTA 도전

MAT는 데이터 매니폴드 구조를 이용하므로

증강이 과해져도 그 증강을 geometrical manifold 관점에서 정리하여 학습하는 구조

라는 이야기를 empirical하게 보여줄 수 있음

근거

ViT를 ImageNet만으로 학습 가능하게 만들기 위해

강력한 어그멘테이션, 레귤러라이제이션, distillation을 총동원

구조는 ViT-B와 동일하지만 트레이닝 레시피 최적화만으로 성능을 크게 끌어올렸음

→ “레시피 튜닝” 자체가 ViT 연구에서 핵심 축

Training data-efficient image transformers & distillation through attention, Hugo Touvron Et al., 2021

근거

데이터 쌍을 선형 결합하는 mixup이 여러 데이터셋에서

일반화 향상,

라벨 노이즈에 대한 견고성,

adversarial robustness 개선을 동시에 달성

mixup: BEYOND EMPIRICAL RISK MINIMIZATION, Hongyi Zhang Et al., 2018

근거

이미지를 잘라 붙이는 **CutMix**로

CIFAR·ImageNet에서 SOTA와 경쟁하는 성능

+ localization, transfer 성능 향상

+ 일부 robustness 향상

CutMix: Regularization Strategy to Train Strong Classifiers with Localizable Features Sangdoo Yun Et al., 2019

근거

RandAugment: 별도의 검색 없이도 강력한 자동 어그멘테이션으로

CIFAR·ImageNet SOTA에 근접 또는 초과

RandAugment: Practical automated data augmentation with a reduced search space, Ekin D Et al., 2019

근거

AugMix: 단순한 조합식 변환으로 ImageNet-C에서 corruption robustness 크게 개선

AUGMIX: A SIMPLE DATA PROCESSING METHOD TO IMPROVE ROBUSTNESS AND UNCERTAINTY, Dan Hendrycks Et al., 2020

근거

DeepAugment(+AugMix): distribution shift·OOD에 대한 robustness를 크게 향상

기존보다 1000배 많은 라벨 데이터를 쓰는 것보다 효과적

The Many Faces of Robustness: A Critical Analysis of Out-of-Distribution Generalization, Dan Hendrycks Et al., 2021

노이즈 추가 후 SOTA 모델들과의 강건성 대결

데이터가 놓여 있는 매니폴드 구조를 명시적으로 학습해서,

노이즈나 외부 환경 변화에 휘둘리지 않고 본질적인 구조에 집중하는 ViT

노이즈 추가 후 SOTA 모델들과의 강건성 대결

깨끗한 데이터에서의 accuracy뿐 아니라

실제로 Gaussian Noise, Blur, Compression, Occlusion, Adversarial noise에서

다른 ViT·Swin·ConvNeXt보다 성능이 덜 떨어진다는 것을 수치로 확인

노이즈 추가 후 SOTA 모델들과의 강건성 대결

학습이 오래 갈수록 representation이 안정해지는 패턴!

노이즈 추가 후 SOTA 모델들과의 강건성 대결

Hendrycks & Dietterich는 Gaussian noise, blur, weather, digital corruption 등

손상을 정의한 ImageNet-C와,

perturbation 연속성을 평가하는 ImageNet-P 제안

“정확도 향상이 robustnes 향상으로 이어지지 않으며,

오히려 최신 모델도 common corruption에 매우 취약하다”

BENCHMARKING NEURAL NETWORK ROBUSTNESS TO COMMON CORRUPTIONS AND PERTURBATIONS, Dan Hendrycks Et al., 2019

노이즈 추가 후 SOTA 모델들과의 강건성 대결

AugMix는 단순한 augmentation 조합만으로도

ImageNet-C에서의 corruption robustness를 크게 끌어올리며,

기존 모델 대비 OOD 성능 격차를 절반 이상 줄인다

→ “robustness는 clean accuracy와 별도의 축이며, 별도 실험으로 반드시 측정해야 한다

AugMix: A Simple Data Processing Method to Improve Robustness and Uncertainty, Dan Hendrycks Et al., 2019

노이즈 추가 후 SOTA 모델들과의 강건성 대결

다양한 distribution shift (ImageNet-R, ImageNet-A 등)를 다루며,

DeepAugment + AugMix와 같은 기법이

corruption·style·adversarial 등

여러 형태의 robustness를 동시에 개선한다는 것

The Many Faces of Robustness: A Critical Analysis o Out-of-Distribution Generalization, Dan Hendrycks Et al.,2020

Experiments