Mathematical theorems

김영은

Topological Foundations

1. Simplical Complex (단체 복합체)
2. Nerve Theorem (신경 정리)

1. Simplical Complex

$$K = \{\sigma \subset V | \sigma = \emptyset, \sigma \in K \Rightarrow \tau \subseteq \sigma \Rightarrow \tau \in K\}$$

만약 σ 가 포함된다면, 그 부분집합 τ도 반드시 포함됨

V = 꼭짓점의 집합 (vertex sets)

ex)

- |σ| = 1 → 점 (0-simplex)
- |σ| = 2 → 선분 (1-simplex)
- |σ| = 3 → 삼각형 (2-simplex)

삼각형 $\{v_1, v_2, v_3\}$ 가 있으면, 그 변 $\{v_1, v_2\}$와 점 $\{v_1\}$도 삼각형에 포함됨
삼각형을 그린다면, 그 삼각형을 이루는 선과 점도 반드시 포함된다.

2. Nerve Theorem

$$X \simeq N(\mathcal{U})$$

만약 σ 가 포함된다면, 그 부분집합 τ도 반드시 포함됨

X : 원래의 위상 공간

$\mathcal{U} = \{U_i\}$: 열린 집합들의 덮개

$N(\mathcal{U})$: nerve complex = $U_{i_0} \cap U_{i_1} \cap \cdots \cap U_{i_k} \neq \emptyset$ 일 때,

단체 $[i_0, i_1, \ldots, i_k]$ 를 포함하는 simplical complex

$\simeq$: homotopy equivalence, 두 공간이 위상적으로 '같은 뼈대구조'

ex) nerve complex는 단순히 '집합이 겹치는 관계만 본 추상적 그래프인데도,
원래 공간과 같은 위상적 형태를 보존

2. Nerve Theorem

위상적으로 같다 : 본질이 같다 (구멍이 몇개 뚫려있는지, 연결이 어떻게 되어있는지)

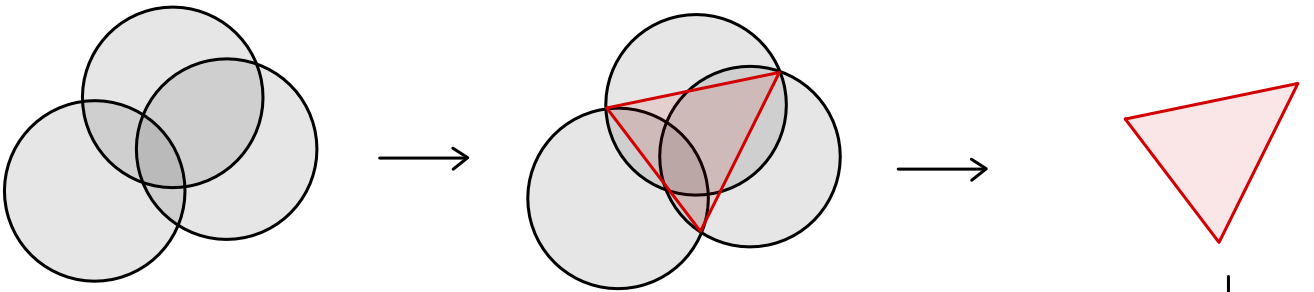

두 그림은 위상적으로 같은 구조를 가진다

Measurable Theory

1. Measurable Space
2. Fuzzy simplicial complex

1. Measure Space

$$\mu : \mathcal{F} \to [0, \infty], \quad \mu\left(\bigcup_{i=1}^{\infty} A_i\right) = \sum_{i=1}^{\infty} \mu(A_i)$$

F : 가측 집합들의 집합 (사건모음)

μ : 각 사건에 크기 (or 확률)을 부여하는 함수

σ- 가법성: 서로 겹치지 않는 무한개의 set A_i 들의 합집합의 크기는 각 크기의 합과 같음

ex) 여러개의 물컵에 든 물 = 다 합쳤을 때의 물

2. Fuzzy Simplicial Complex

$$\mu : \sigma \mapsto [0, 1]$$

σ : simplex (ex - 점, 선, 삼각형)

$\mu(\sigma)$: 그 simplex가 구조에 ‘얼마나 소속되는지‘ 나타내는 값

$\mu = 1$: 완전 포함

$\mu = 0.3$: 0. 3%만 소속

ex) UMAP같은 차원축소 기법에서, data point들의 관계를 ‘fuzzy'한 simplicial complex로 모델링

→ 확률적 연결관계로 해석 가능

2. Fuzzy Simplicial Complex

축구부를 만든다고 했을 때

축구를 매일 하는 학생은 → $\mu = 1$ (완전 소속)

가끔만 하는 학생은 → $\mu = 0.3$ (애매한 소속)

전혀 안 하는 학생은 → $\mu = 0$ (소속 아님)

→ 누가 축구부에 얼마나 속해있는지의 애매한 정도를 나타낸 것

Riemannian Geometry - Expotential Map

$$\exp_p(v) = \gamma_v(1)$$

→ 접공간의 벡터를 다양체 위의 실제 점으로 옮기는 함수

$P \in M$: 다양체 M위의 점

T_pM : p에서의 접공간, 평면처럼 펼친 공간

$v \in T_pM$: 접공간의 벡터

$\gamma_v(t)$: p에서 출발, 초기속도 v를 가진 geodesic (최단경로곡선)

$exp_p(v)$ t = 1 일때의 곡선위치

ex) 지도 위에서 '서울에서 동쪽으로 100km의 벡터'를 실제 지구표면위의 지점으로 바꾸는 과정

Riemannian Geometry - Expotential Map

$$\exp_p(v) = \gamma_v(1)$$

서울을 지구 위의 한 점 P라고 함

지도를 평면으로 펴놓고, “동쪽으로 100km”라는 화살표 v를 그림

하지만 지구는 둥글기 때문에, 실제로 그 방향·거리를 지구 위에 옮기면 다르게 나타남

→ 이 변환 과정이 Exponential Map임

Manifold (다양체)

$$\forall p \in M,\ \exists U \ni p,\ \varphi : U \to \mathbb{R}^n$$

임의의 점 p 근처에는 열린집합 U가 있고, 이를 R^n 과 위상적으로 동일하게 보는 함수 φ 가 있음

전체적으로는 곡선 / 곡면이지만, 국소적으로는 평면처럼 보임

ex) 지구는 둥글지만, 서울 근처만 가까이 보면 평평한 지도처럼 보임

Graph Layout Optimization (Fruchterman - Reingold model)

$$f_a(d) = \frac{d^2}{k} \qquad f_r(d) = \frac{k^2}{d}$$

Graph layout algorithm → ‘모든 node'를 밀고 당기면서 에너지의 최소위치를 찾음

d : 두 node 사이의 거리
k : 이상적 간격 (보통 $\sqrt{-}$)
$f_a(d)$: Attraction Force (인접 node간 당기는 힘)
d^2에 비례 → 멀리 떨어지면 더 강하게 당김
$f_r(d)$: Repulsion Force (모든 node간 밀어내는 힘)
1/d에 비례 → 가까우면 강하게 밀어냄

ex) 연결된 자력 있는 쇠구슬들이 서로 밀어내며 안정된 모양을 잡는 것

Graph Layout Optimization (Fruchterman - Reingold model)

여러 친구들이 고무줄로 연결되어 있다...

연결된 친구끼리는 멀리 떨어져 있으면 끌려가고, 너무 가까이 있으면 서로 불편해서 밀어냄

이게 노드간의 관계임

UMAP: Uniform Manifold Approximation and Projection for Dimension Reduction (Mcinnes et al., 2020)

UMAP은 차원 축소 알고리즘 (리만 기하학 + 대수적 위상수학(특히 fuzzy simplicial set) 기반)

특징:

t-SNE와 유사한 시각화 품질

더 큰 데이터셋에도 효율적으로 확장 가능

임베딩 차원에 제한 없음(범용 차원 축소 알고리즘)

이론적 기반

균일 분포 가정과 지역 거리 정규화

데이터 $X = \{x_1, x_2, \ldots, x_N\}$가 매니폴드 M위에 있다고 가정

KNN 을 통해 지역적인 균일 분포를 근사
→ i번째 점 x_i 에서:

$$\rho_i = min\{d(x_i, x_{ij}) | d(x_i, x_{ij}) > 0, j = 1, \ldots, k\}$$

정규화 파라미터 σ_i정의조건:

$$\sum_{j=1}^{k} \exp\left(-\frac{\max(0, d(x_i, x_{ij}) - \rho_i)}{\sigma_i}\right) = \log_2(k)$$

가중 그래프 표현

각 점마다 KNN을 연결한 방향 그래프 $\overline{G} = (V, E, w)$

$$w(x_i, x_j) = \exp\left(-\frac{\max(0, d(x_i, x_j) - \rho_i)}{\sigma_i}\right)$$

이를 fuzzy simplicial set으로 해석,
최종적으로 대칭화하여 무방향 그래프 G 구성:

$$B = A + A^T - A \odot A^T$$

최적화 목적 함수

고차원 그래프와 저차원 임베딩 그래프 간의 차이를 fuzzy set cross entropy로 최소화

두 fuzzzy set에 대해 $(A, \mu), (A, \nu)$

$$C((A,\mu),(A,\nu)) = \sum_{a \in A} \left[\mu(a) \log \frac{\mu(a)}{\nu(a)} + (1-\mu(a)) \log \frac{1-\mu(a)}{1-\nu(a)} \right]$$

계산적 구현 - Attractive / Repulsive Forces

Attractive force(가까운 점 끌어당김)

$$F_{\text{attr}}(i,j) = \frac{2ab\|y_i - y_j\|^{2(b-1)}}{1 + a\|y_i - y_j\|^{2b}} w(x_i, x_j)(y_i - y_j)$$

Repulsive force(멀리있는 점 밀어냄)

$$F_{\text{rep}}(i,j) = \frac{2b\epsilon}{(\epsilon + \|y_i - y_j\|^2)(1 + a\|y_i - y_j\|^{2b})}(1 - w(x_i, x_j))(y_i - y_j)$$

계산적 구현 – Embedding Smooth Approximation

저차원에서 두 점 y_i,y_j 사이 membership strength 근사:

$$\phi(y_i, y_j) = \left(1 + a\|y_i - y_j\|^{2b}\right)^{-1}$$

(a, b: min-dist 하이퍼파라미터에 의해 결정)

알고리즘 요약 (의사코드)

- 데이터셋에서 k-최근접 이웃 찾기 (Nearest Neighbor Descent 사용)
- 각 점의 ρ_i, σ_i 계산
- fuzzy simplicial set 기반 가중 그래프 구성
- 스펙트럴 초기화 (Laplacian eigenvectors)
- Stochastic Gradient Descent(SGD)로 cross-entropy 최소화

정리

UMAP은 고차원 데이터의 친밀도 네트워크를 만들고,

저차원 공간에서 그 관계를 비슷하게 재현하기 위해

점들을 끌어당기고 밀어내면서

최적화하는 차원 축소 알고리즘

Feedback

개념과 수식에 익숙해지기
한번 더 읽기 → 장기기억에 넣기

모든 dataset에 다 사용할 수 있다면, 단점은 뭐일지?

UMAP사용한 논문 읽어보고, 사용하지 않았을때와 성능 비교해보기

Mathematical theorems